

Análisis de Extinción de Incendios mediante Ondas Sonoras utilizando Aprendizaje Automático

Diego Alejandro Carvajal Díaz *Estudiante de Ingeniería de Sistemas, Universidad de Antioquia,*
 Juan Jacobo Palacio Arboleda *Estudiante de Ingeniería de Sistemas, Universidad de Antioquia*

Abstract—Este proyecto utiliza el *Acoustic Extinguisher Fire Dataset*, que contiene 17.442 registros de pruebas con ondas sonoras para extinguir llamas de distintos combustibles. Se analizan 6 variables de entrada y una salida binaria que indica si la llama se extinguió. Tras una caracterización exploratoria, se aplica clasificación supervisada para predecir el estado de extinción, evaluando la efectividad de distintos modelos de machine learning.

Index Terms—Extinción de incendios, ondas sonoras, aprendizaje supervisado, clasificación binaria, análisis predictivo

I. INTRODUCCIÓN

LA detección y supresión de incendios representa un área fundamental en la ingeniería de seguridad. En los últimos años, se han investigado métodos alternativos como el uso de ondas sonoras, los cuales prometen una extinción de llamas más controlada y con menor impacto ambiental. En este contexto, el *Acoustic Extinguisher Fire Dataset* proporciona 17.442 registros experimentales obtenidos al aplicar ondas acústicas sobre llamas generadas por diferentes combustibles, permitiendo explorar la viabilidad de este enfoque innovador. Cada registro incluye seis variables de entrada relacionadas con condiciones acústicas y ambientales, así como una variable binaria que indica si la llama fue extinguida.

Este estudio aborda el problema como una tarea de **clasificación supervisada**, donde a partir de variables acústicas y ambientales se predice la efectividad del proceso de extinción. El análisis comparativo de múltiples algoritmos busca identificar aquellos con mayor potencial para integrarse en sistemas inteligentes de control de incendios, contribuyendo al desarrollo de tecnologías no convencionales en este campo.

II. DESCRIPCIÓN DEL PROBLEMA

A. Extinción de Incendios mediante Ondas Sonoras

La extinción de incendios mediante ondas sonoras es una técnica no convencional que emplea vibraciones acústicas para alterar las condiciones que permiten la combustión. Esta metodología actúa sobre la dinámica de los tres elementos esenciales del fuego: calor, combustible y oxígeno. Al aplicar frecuencias bajas, generalmente entre **20 y 120 Hz**, se generan variaciones de presión en el aire que inducen inestabilidad en la llama. Estas fluctuaciones pueden contribuir a la disipación del calor y al desplazamiento del oxígeno en la zona de combustión, interfiriendo con el equilibrio energético necesario para mantener el fuego.

B. Descripción de la Composición de Datos

El conjunto de datos utilizado para el estudio consta de 17,442 muestras, cada una representando un experimento donde se aplicaron ondas acústicas a llamas generadas por diferentes combustibles, con el objetivo de determinar si la llama fue extinguida exitosamente.

Cada muestra contiene **7** variables, de las cuales 6 son características predictoras y 1 es la variable objetivo. A continuación, se describe cada una de ellas junto con su tipo, unidades y rango de valores observados:

- **SIZE (int)**: Representa el tamaño de la llama según el tamaño del recipiente para combustibles líquidos o el ajuste del gas para el combustible LPG. Los valores están codificados como:
 - 1 = 7 cm
 - 2 = 12 cm
 - 3 = 14 cm
 - 4 = 16 cm
 - 5 = 20 cm
 - 6 = Half throttle (LPG)
 - 7 = Full throttle (LPG)
- **FUEL (string)**: Tipo de combustible utilizado. Puede tomar uno de los siguientes valores:
 - Gasoline
 - Kerosene
 - Thinner
 - LPG
- **DISTANCE (int)**: Distancia entre la fuente del sonido y la llama, en centímetros. Rango: 10 a 190 cm, en incrementos de 10 cm.
- **DESIBEL (int)**: Nivel de intensidad sonora medida durante el experimento. Rango: 72 a 113 dB.
- **AIRFLOW (float)**: Velocidad del flujo de aire generado por las ondas acústicas. Rango: 0.0 a 17.0 m/s.
- **FREQUENCY (int)**: Frecuencia de la onda acústica aplicada. Rango: 1 a 75 Hz.
- **STATUS (int)**: Variable objetivo que indica si la llama fue extinguida (1) o no (0).

La distribución de clases es prácticamente balanceada:

- 8,683 (49.8%) corresponden a experimentos donde la llama fue extinguida exitosamente (STATUS = 1).
- 8,759 (50.2%) corresponden a experimentos donde la llama no fue extinguida (STATUS = 0).

No se encontraron valores faltantes en ninguna de las variables, lo cual facilita el procesamiento y análisis del conjunto de datos.

C. Paradigma de Aprendizaje Seleccionado

Dado que el objetivo principal del proyecto es predecir si una llama será extinguida (STATUS = 1) o no (STATUS = 0) a partir de un conjunto de variables de entrada cuantitativas y cualitativas, el equipo decidió adoptar el paradigma de aprendizaje supervisado, específicamente en su modalidad de clasificación binaria.

Este tipo de aprendizaje es apropiado debido a que el conjunto de datos proporciona instancias etiquetadas, es decir, ejemplos previos donde se conoce el resultado (éxito o fracaso de la extinción de la llama) en función de las condiciones experimentales. De esta forma, es posible entrenar modelos capaces de aprender patrones en los datos y generalizar a nuevas situaciones.

III. ESTADO DEL ARTE

Se revisaron dos artículos científicos relacionados con la extinción de llamas mediante ondas sonoras y el uso de técnicas de aprendizaje automático para predecir la efectividad del proceso:

A. Artículo 1: "A Comparative Analysis of Machine Learning Approaches for Sound Wave Flame Extinction System Towards Environmental Friendly Fire Suppression" [1]

- **configuración:** Aprendizaje supervisado, clasificación binaria (extingue / no extingue)
- **Técnicas:** Logistic Regression, Gaussian Naive Bayes, Linear Discriminant Analysis, K-Nearest Neighbors, Decision Tree, Random Forest, Extra Trees, XGBoost
- **Validación:** 10-fold stratified cross-validation, Hold-out split 80% train / 20% test (utilizada tras la optimización de hiper-parámetros con RandomSearchCV)
- **Métricas:** Accuracy: 0.98, Precision / Recall / F1 (características seleccionadas, parámetros por defecto): 0.99 / 0.98 / 0.98 (clase "Extinguishing") y 0.98 / 0.99 / 0.98 (clase "Non-extinguishing")
- **Resultados Obtenidos:** Los autores identificaron el modelo **XGBoost** como el más efectivo para clasificar la extinción de llamas por ondas sonoras. Este modelo alcanzó una precisión del **98.31%** con parámetros por defecto y del **98.62%** tras la optimización de sus hiperparámetros. Estos resultados sugieren una fuerte correlación entre los parámetros acústicos y la eficacia en la supresión del fuego.

B. Artículo 2: "Classification of flame extinction based on acoustic Oscillations using artificial intelligence methods" [2]

- **configuración:** Aprendizaje supervisado, clasificación binaria
- **Técnicas:** ANFIS, CN2 Rule, Decision Trees (DT)
- **Validación:** 10-fold stratified cross-validation, Hold-out split 80% train / 20% test (utilizada tras la optimización de hiper-parámetros con RandomSearchCV)
- **Métricas:** Accuracy: 99.91%, Precision 99.82 %, Recall 100%, F1 99.91%, Especificidad (SPC) 99.83% Para CN2.

- **Resultados Obtenidos:** El modelo CN2 Rule mostró el mayor éxito de clasificación, además de los valores más altos en F1-score, Precision, Sensitivity y Specificity (con 0.9991, 0.9982, 1.0 y 0.9983 respectivamente), lo que lo posiciona como el más robusto entre los modelos evaluados para la predicción de la extinción de la llama.

C. Artículo 3: "Determining the Extinguishing Status of Fuel Flames With Sound Wave by Machine Learning Methods" [3]

- **configuración:** Clasificación binaria supervisada para predecir si una llama se extingue (1) o no (0) tras aplicar ondas sonoras. Se utilizó el *Acoustic Extinguisher Fire Dataset*, compuesto por 17,442 registros experimentales con seis variables de entrada (acústicas y ambientales) y una variable objetivo binaria.
- **Técnicas:** Se evaluaron cinco modelos de aprendizaje automático: Artificial Neural Network (ANN), k-Nearest Neighbors (k-NN), Random Forest (RF), Deep Neural Network (DNN) y un modelo de ensamble Stacking que combina ANN, k-NN y RF.
- **Validación:** Se aplicó validación cruzada estratificada de 10 pliegues para evaluar todos los modelos de forma consistente y obtener métricas generalizables.
- **Métricas:** Las métricas empleadas incluyeron Accuracy, F1-score (FSC), Precision (PRE), Recall (RCL), Specificity (SPC), Negative Predictive Value (NPV), False Positive Rate (FPR) y False Negative Rate (FNR). El modelo Stacking obtuvo los mejores resultados con una Accuracy de 97.06%. RF alcanzó 96.58%, ANN 96.03%, DNN 94.88% y k-NN 92.62%.
- **Resultados Obtenidos:** El modelo **Stacking** fue el más efectivo, con el mayor rendimiento en todas las métricas evaluadas. Se concluyó que todas las variables del dataset influyen en frecuencia la más determinante. El estudio también reportó rangos efectivos de extinción entre 10–50 Hz dependiendo de la distancia y tipo de combustible, lo cual refuerza el potencial de un sistema de soporte a decisiones basado en ML para control de extinción acústica.

D. Artículo 4: "Control of Acoustic Extinguisher with Deep Neural Networks for Fire Detection" [4]

- **configuración:** Sistema híbrido de detección y supresión de incendios que integra redes neuronales profundas para detección visual con un extintor acústico de alta potencia.
- **Técnicas:** Se entrenó una **Mask R-CNN** con arquitectura Inception en TensorFlow, capaz de segmentar instancias de fuego en imágenes y videos. El sistema fue implementado en una plataforma NVIDIA Jetson Nano para inferencia en tiempo real.
- **Validación:** Se usaron 400 imágenes de prueba no vistas durante el entrenamiento, así como videos reales descargados de YouTube. Se evaluó el desempeño visual de detección y la activación del extintor.
- **Métricas:** Tasa de detección de incendios: **86%** de precisión en imágenes estáticas. También se analizaron el nivel de presión sonora (SPL) y la potencia mínima

requerida para lograr la extinción efectiva a distintas frecuencias (15 Hz, 17 Hz y 20 Hz) y distancias (0.1 m a 0.7 m).

- **Resultados Obtenidos:** La red neuronal detectó correctamente la presencia de fuego en imágenes complejas y videos. Se logró la extinción de llamas (velas) mediante ondas acústicas de alta potencia moduladas en amplitud, con frecuencias bajas (15–20 Hz). El estudio demuestra que es posible implementar un sistema de extinción autónomo y no invasivo controlado por IA, aunque todavía se requieren mejoras en robustez y portabilidad.

IV. ENTRENAMIENTO Y EVALUACIÓN DE LOS MODELOS

A. Configuración Experimental

Para evaluar el desempeño de diferentes clasificadores en el problema de predicción de la extinción de fuego mediante ondas acústicas, se utilizaron cinco algoritmos de aprendizaje supervisado: Regresión Logística, K-Nearest Neighbors (KNN), Random Forest, XGBoost y Perceptrón Multicapa (MLPClassifier).

Se empleó una partición estratificada del conjunto de datos escalado, dividiendo en 80% para entrenamiento y 20% para prueba. A continuación, cada modelo fue ajustado con los datos de entrenamiento y evaluado con los datos de prueba utilizando métricas de *Accuracy* y *F1-Score ponderado*.

La TABLE I presenta los resultados obtenidos:

TABLE I
DESEMPEÑO DE LOS MODELOS DE CLASIFICACIÓN

Modelo	Accuracy	F1-Score
Logistic Regression	0.8919	0.8919
KNN	0.9582	0.9582
Random Forest	0.9659	0.9659
XGBoost	0.9788	0.9788
MLPClassifier	0.9584	0.9584

Como se puede observar, el modelo XGBoost obtuvo el mejor rendimiento general, alcanzando una precisión y un F1-Score de 97.88%, lo que lo posiciona como el modelo más prometedor para el problema planteado. Los modelos Random Forest y MLPClassifier también presentaron desempeños competitivos, superando el 95% en ambas métricas.

V. REDUCCIÓN DE DIMENSIÓN

Para analizar la posibilidad de simplificar el conjunto de datos sin perder demasiada información, se aplicó Análisis de Componentes Principales (PCA). Inicialmente, se estimó la varianza explicada acumulada por cada componente principal, como se muestra en la Fig. 1.



Fig. 1. Varianza explicada acumulada por número de componentes principales.

A partir del gráfico, se observó que los primeros cuatro componentes explicaban aproximadamente el 82.3% de la varianza total. Por tanto, se seleccionaron 4 componentes para la reducción, resultando en una disminución del 50% en la dimensionalidad del conjunto de datos (de 8D a 4D).

Posteriormente, se evaluó el desempeño de los dos mejores modelos previamente seleccionados (XGBoost y Random Forest) sobre los datos transformados con PCA. La TABLE II resume los resultados obtenidos:

TABLE II
DESEMPEÑO DE MODELOS TRAS REDUCCIÓN DE DIMENSIÓN CON PCA

Modelo	Componentes	Varianza Explicada	Reducción Dimensional	Accuracy F1-Score
XGBoost	4	82.3%	50.0%	0.9603
Random Forest	4	82.3%	50.0%	0.9568

Los resultados indican que ambos modelos mantienen un rendimiento elevado incluso tras la reducción dimensional, lo que demuestra que PCA es una herramienta eficaz para simplificar los datos conservando la mayoría de su información útil.

A. Visualización en 2D mediante PCA

Para facilitar la exploración visual de los datos, se aplicó la técnica de Análisis de Componentes Principales (PCA), reduciendo el conjunto de características a dos componentes principales. En la Fig. 2, se presenta la distribución de las observaciones proyectadas en este espacio bidimensional, coloreadas según la variable objetivo STATUS.

En la visualización se observa una leve estructura de agrupación, en la que los puntos con diferente clase tienden a concentrarse en distintas regiones del espacio PCA. Sin embargo, también existe superposición entre las clases, lo cual indica que la separación no es perfectamente lineal en este plano. Esta representación es útil como paso exploratorio, pero sugiere que se requerirán modelos de clasificación más complejos para lograr una separación efectiva entre clases.




Fig. 2. Visualización 2D de los datos tras aplicar PCA.

B. Análisis de Componentes Principales

Para interpretar la naturaleza de los componentes extraídos mediante PCA, se examinó la contribución (carga) de cada variable original en los primeros cuatro componentes principales. La TABLE III muestra las variables con mayor peso absoluto en cada componente.

TABLE III
VARIABLES CON MAYOR CONTRIBUCIÓN EN LOS COMPONENTES PRINCIPALES

Componente Principal	Variable de Mayor Contribución
1	AIRFLOW
2	FUEL_lpg
3	FREQUENCY
4	FUEL_thinner

Este análisis sugiere que ciertas variables —como el flujo de aire (AIRFLOW), el tipo de combustible (FUEL_lpg) y la frecuencia (FREQUENCY)— son determinantes en la variabilidad del conjunto de datos, lo cual puede ser útil para futuras tareas de selección de características o interpretabilidad del modelo.

C. Validación con una Variable Categórica Binaria

Como parte del análisis exploratorio, se creó una variable categórica binaria denominada LPG_THROTTLE, la cual toma el valor 1 si el valor de la columna SIZE corresponde a 6 o 7, y 0 en caso contrario. Esta transformación se basó en la observación empírica del comportamiento del sistema bajo distintas condiciones de operación.

En la Fig. 3, se presenta la distribución de esta nueva variable agrupada por la variable objetivo STATUS.

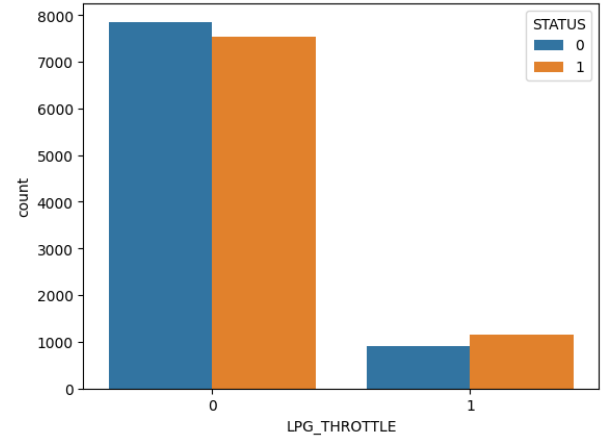


Fig. 3. Distribución de la variable binaria LPG_THROTTLE por clases de STATUS.

La gráfica sugiere que el encendido de la llama (STATUS = 1) se presenta ligeramente con mayor frecuencia cuando el sistema está en modo de aceleración (LPG_THROTTLE = 1), lo cual es coherente con la dinámica del comportamiento físico del dispositivo. Esta validación cualitativa permite respaldar las transformaciones de variables realizadas para el modelado posterior.

En la TABLE IV se observa que XGBoost obtiene el mejor desempeño, con un accuracy y F1-Score de 0.9653. Le siguen MLPClassifier y KNN, con métricas superiores al 95

TABLE IV
DESEMPEÑO DE LOS MODELOS DE CLASIFICACIÓN CON LOS DATOS ORIGINALES

Modelo	Accuracy	F1-Score
Logistic Regression	0.8911	0.8911
KNN	0.9516	0.9516
Random Forest	0.9513	0.9513
XGBoost	0.9653	0.9653
MLPClassifier	0.9587	0.9587

D. Reducción de Dimensión con Análisis de Componentes Principales (PCA)

Para explorar la posibilidad de reducir la dimensionalidad del conjunto de datos sin perder información significativa, se aplicó el Análisis de Componentes Principales (PCA). En la Fig. 4 se presenta la varianza explicada acumulada en función del número de componentes principales.

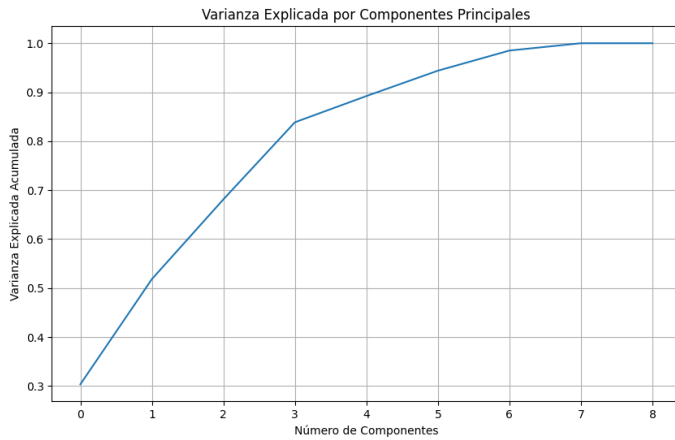


Fig. 4. Varianza explicada acumulada por los componentes principales

Como se observa en la gráfica, los primeros **4 componentes** explican aproximadamente el **83.86%** de la varianza total. A partir de este punto, añadir más componentes contribuye muy poco al aumento de la varianza explicada, lo que sugiere que es un umbral adecuado para la reducción de dimensionalidad.

Se redujo el conjunto original de **9 características** a **4 componentes**, lo que representa una disminución del **55.6%** en la dimensionalidad. Esta reducción permite simplificar el modelo y mejorar la eficiencia computacional, sin sacrificar gran parte de la información contenida en los datos originales.

E. Evaluación de Modelos con Dimensionalidad Reducida

Con el objetivo de reducir la complejidad del modelo sin sacrificar precisión, se evaluaron los dos mejores clasificadores (XGBoost y Random Forest) utilizando las **4 componentes principales** seleccionadas mediante PCA, las cuales retienen aproximadamente el **83.9%** de la varianza del conjunto original. Esta transformación implicó una reducción del **55.6%** en la dimensionalidad.

TABLE V
RENDIMIENTO DE LOS MODELOS CON 4 COMPONENTES PRINCIPALES (PCA)

Modelo	Reducción Dimensional	Accuracy	F1-Score
XGBoost	55.6%	0.9555	0.9555
Random Forest	55.6%	0.9517	0.9517

Los resultados muestran que, pese a la significativa reducción de características, ambos modelos mantuvieron un alto rendimiento. El clasificador XGBoost obtuvo un **F1-score de 0.9555**, prácticamente igual a su desempeño original sin PCA. Esto sugiere que la mayor parte de la información relevante para la predicción fue preservada en las componentes seleccionadas.

Además, se analizó la contribución de las variables originales a cada componente principal. Las características que más aportaron a cada uno de los cuatro componentes fueron:

- **Componente 1:** LPG_THROTTLE
- **Componente 2:** AIRFLOW
- **Componente 3:** FREQUENCY
- **Componente 4:** FUEL_thinner

Este análisis evidencia que ciertas variables tienen un mayor peso en la estructura latente de los datos y podrían considerarse prioritarias en tareas de selección de características o explicación de modelos.

REFERENCES

- [1] R. G. de Luna et al., "A comparative analysis of machine learning approaches for sound wave flame extinction system towards environmental friendly fire suppression," in *2023 IEEE Region 10 Conference (TENCON)*, Chiang Mai, Thailand, 2023, DOI: 10.1109/TENCON58879.2023.10322502.
- [2] Y. S. Taspinar, M. Koklu, and M. Altin, "Classification of flame extinction based on acoustic oscillations using artificial intelligence methods," *Case Studies in Thermal Engineering*, vol. 28, p. 101561, 2021. DOI: 10.1016/j.csite.2021.101561.
- [3] M. Koklu and Y. S. Taspinar, "Determining the Extinguishing Status of Fuel Flames with Sound Wave by Machine Learning Methods," in *2023 IEEE 13th Annual Computing and Communication Workshop and Conference (CCWC)*, IEEE Access, vol. 9, pp. 86207 - 86216, 2021, DOI: 10.1109/ACCESS.2021.3088612.
- [4] J.Ł. Wilk-Jakubowski, P. Stawczyk, S. Ivanov and S. Stankov, "Control of Acoustic Extinguisher with Deep Neural Networks for Fire Detection," in *2022 Elektronika ir Elektrotechnika*, DOI: DOI:10.5755/j02.eie.24744